



TMiT

Weboldal-ujjlenyomat-készítés (Website Fingerprinting) vizsgálata Tor hálózaton

Készítette: Pálos Ferenc · Konzulens: Dr. Ladóczy Bence

ÖNÁLLÓ LABORATÓRIUM · 2026

Kiindulási állapot és Célkitűzés

Probléma

A Tor hálózatba belépő forgalomból a weboldal-ujjlenyomat-készítés (WF) révén következtetni lehet a meglátogatott oldalakra


Kiindulás

A projekt kód, adathalmaz és előzetes mérési eredmények nélkül, az alapoktól indult

Cél

A WF támadások vizsgálata valós forgalomban — normál Tor és obfs4 forgalom-elfedő modul mellett

Saját Munka: Az Adatfeldolgozási Lánc



Adatgyűjtési Szcenáriók

Adathalmaz

36 előre ismert (zárt világú) és 20 ismeretlen („Other”, nyílt világú) webhely rögzítése

Technológia

Headless Chromium böngésző, Selenium vezérlés és Tor SOCKS/ControlPort automatizáció

Mérési protokoll

3 másodperces bemelegítési (warmup) fázis a hálózati útvonalak stabilizálására, majd 15 másodperc aktív rögzítés

Alkalmazott Modellek

Random Forest (RF)

300 döntési fát alkalmazó,
robusztus klasszikus gépi tanulási
modell


Triplet MLP + KNN (DL)

Reprezentáció-tanuláson alapuló
architektúra, 32 dimenziós
beágyazási térrel és $k=5$
paraméterű KNN osztályozóval

Metrikák

A teljesítmény mérése pontosság
(accuracy) és macro-F1 értékek
alapján

Zárt Világú (Closed-World) Eredmények



Baseline forgalom

A Random Forest (80,44 % pontosság) felülmúlja a Triplet MLP-t (61,19%)

Obfs4 forgalom

A pontosság csökken, de a Random Forest (73,33%) itt is jobban teljesít, mint a mélytanulási modell (50,64%)

Konklúzió

A kézzel tervezett (hand-crafted) aggregált jellemzők hatékonyak a megegyező (tanító és teszt) környezetben

Eloszlás-eltolódás és Zero-Shot Értékelés

Környezet


Betanítás baseline adatokon, kiértékelés obfs4 forgalmon

Eredmény

Drasztikus teljesítményromlás mindkét modellnél az eloszlás-eltolódás (domain shift) miatt


Általánosítás

A Triplet MLP stabilabb (23,01% pontosság) a Random Forestnél (15,08%), ami robusztusabb beágyazási teret igazol



Nyílt Világú (Open-World) Vizsgálat

Az „Other” Osztály Visszahívása



Feladat

Az ismeretlen ("Other") és a zárt világú webhelyek elkülönítése

Visszahívás (Recall)

Kiemelkedő felismerési arány az ismeretlen forgalomra (RF: 96,9%)

Kihívás

Magas visszahívás, drasztikusan csökkenő precízió és macro-F1 érték

A Megközelítés Korlátai



Információvesztés

Aggregált statisztikák miatti
csomagszintű dinamika-vesztés



Dimenziócsökkentés

A top-10 jellemző korlátja szűkíti
a reprezentációs kapacitást



Heterogenitás

A nyílt világú forgalom
komplexitása akadályozza az
éles döntési határokat

Összefoglalás és Jövőbeli Tervek

1

Eredmény

Működő, automatizált WF kiértékelési keretrendszer készült el

2

Kutatási irány

Az időbeli statisztikai eltolódás (concept drift) vizsgálata friss adathalmazok periodikus bevonásával

3

Fejlesztés

Komplexebb, nyers csomag-idősorokat feldolgozó mélytanulási architektúrák integrálása