

# Tor Website Fingerprinting

## Önálló laboratórium beszámoló

Pálos Ferenc

2026. május 6.

### Összefoglaló

A beszámoló a Tor hálózaton végzett weboldal ujjlenyomat-készítés (Website Fingerprinting, WF) feladatát mutatja be, két eltérő modelles család összehasonlításával: klasszikus gépi tanulás (Random Forest) és mélytanulás (Triplet MLP + KNN). A vizsgálat a zárt világú (baseline, obfs4), a zero-shot és a nyílt világú (open-world) forgatókönyvekben méri a teljesítményt. A végső értékelés a futtatott Python pipeline által számolt metrikákon és a generált ábrákon alapul. A Random Forest erős baseline és obfs4 teljesítményt ad, míg a Triplet MLP a zero-shot beállításokban kedvezőbb általánosítást mutat.

## 1 Célkitűzések és hozzájárulások

A projekt célja egy reprodukálható WF pipeline kialakítása és két modelles család objektív összehasonlítása a Tor forgalomban jelentkező domain shift és ismeretlen forgalom kezelésére. Ennek keretében:

- a PCAP állományoktól a kiértékelési metrikákig egy végig automatizált feldolgozási láncot raktam össze,
- aggregált folyamjellemzőket definiáltam és egységes 21-dimenziós feature teret alkalmaztam,
- *shared* és *optimized* top-10 feature track-eket vezettem be,
- egységes ábragenerálást biztosítottam a kiértékelési JSON-okból.

## 2 Adatok és forgatókönyvek

A mérés három adatdoménen történik: baseline Tor forgalom, obfs4 Tor forgalom, valamint az open-world „Other” kategória. A fő forgatókönyvek:

- **Baseline (closed-world):** standard Tor böngészés.
- **Obfs4 (closed-world):** obfs4 pluggable transport által elfedett forgalom.
- **Zero-shot:** baseline-on tanított modellek tesztelése obfs4 forgalmon.
- **Open-world:** „Other” kategória hozzáadása az ismeretlen oldalak modellezésére.

Az open-world „Other” osztályt 50%-50% arányban bontom tanító/teszt részre, hogy valós idejű ismeretlen forgalom esetét szimuláljam.

### 3 Feldolgozási pipeline és jellemzők

A pipeline három lépésből áll. **(1)** A PCAP fájlokból kiolvasom az egyes csomagokat, és csomagonkénti idősorokat készítek (mikor jött a csomag, mekkora volt, milyen irányban haladt). **(2)** Ezekből az idősorokból egy-egy kapcsolatot összefoglaló, aggregált jellemzőket számolok. Ilyenek például az összes be- és kimenő csomagszám, a be- és kimenő bájtok összege, a csomagok közti érkezési idők statisztikái (átlag, szórás, percentilis), a kapcsolat időtartama, illetve az irányváltások száma. **(3)** A jellemzőkön tanítom és értékelem a modelleket.

### 4 Modellek és kiértékelés


**Random Forest.** 300 döntési fából álló modell, stabilizált top-10 jellemzőkiválasztással és három véletlen maggal (42, 52, 62). A három mag azt jelenti, hogy a tanító/teszt felosztást és a modell tanítását háromszor ismétlem, majd átlagot és szórást számolok.

**Triplet MLP + KNN.** A Triplet MLP 32 dimenziós beágyazást tanul. A Triplet Margin Loss arra kényszeríti a modellt, hogy az azonos weboldalhoz tartozó minták beágyazása közel legyen, míg a különböző weboldalaké távol. A beágyazásokon  $k = 5$  KNN osztályozást végzek.


**Feature track-ek.** *shared* track-ben egy közös top-10 készletet választok ki a mutual information alapján. *optimized* track-ben forgatókönyvenként külön top-10 készlet készül (RF: több futásból stabilizált fontossági rangsor, DL: mutual information).

### 5 Ábrák és vizuális összegzés


A `generate_all_figures.py` szkript a mentett metrikákból generálja a végső ábrákat, ezért az ábrák és a táblázatok ugyanabból a kiértékelési kimenetből készülnek.



1. ábra. Zárt világú teljesítmény-összegzés (pontosság és macro-F1) a két modellre.




2. ábra. Macro-F1 alakulása minden forgatókönyvben, zárt és nyílt világú esetekben.




3. ábra. A *shared* és *optimized* track-ek közti különbségek (delta) pontosságban és macro-F1-ben.

## 6 Kísérleti beállítások


A tanítás és kiértékelés rétegzett tanító/teszt felosztással történik. A stabilitást három véletlen mag biztosítja (42, 52, 62). Az eredményeket átlag  $\pm$  szórás formában közlöm. A metrikák a pontosság (accuracy) és a macro-F1. A zero-shot beállításban a baseline adatokon tanított modelleket obfs4 teszt adatokon értékelem. A táblázatok a *shared* track eredményeit mutatják.



4. ábra. Nyílt világú forgatókönyvek összehasonlítása.




5. ábra. A top-10 jellemzők fontossága a közös (shared) kiválasztás mellett.



6. ábra. Forgatókönyvenként optimalizált top-10 jellemzők összehasonlítása.

## 7 Eredmények



7. ábra. Konfúziós mátrixok a főbb forgatókönyvekben (shared track, seed=42).

1. táblázat. Zárt világú (Standard) forgatókönyvek eredményei.

| Forgatókönyv | RF Acc.    | RF Macro-F1 | DL Acc.    | DL Macro-F1 |
|--------------|------------|-------------|------------|-------------|
| Baseline     | 80.44±0.96 | 79.76±0.99  | 61.19±2.22 | 60.23±2.47  |
| Obfs4        | 73.33±1.78 | 71.88±1.57  | 50.64±2.59 | 49.48±2.70  |
| Zero-Shot    | 15.08±1.37 | 10.83±1.57  | 23.01±2.59 | 18.54±2.64  |

2. táblázat. Nyílt világú (Open-World) forgatókönyvek eredményei.

| Forgatókönyv | RF Acc.    | RF Macro-F1 | DL Acc.    | DL Macro-F1 |
|--------------|------------|-------------|------------|-------------|
| OW-Baseline  | 80.93±0.84 | 79.11±0.68  | 62.00±1.32 | 60.37±0.76  |
| OW-Obfs4     | 74.10±1.59 | 71.03±1.65  | 48.90±2.58 | 48.46±1.78  |
| OW-Zero-Shot | 22.73±1.79 | 10.41±1.00  | 27.27±1.79 | 18.42±0.41  |

## 8 Elemzés és megvitatás

A Random Forest zárt világú baseline és obfs4 környezetben egyértelműen magasabb pontosságot és macro-F1-t ér el, ami a kézzel tervezett aggregált jellemzők hatékony kihasználását jelzi. A zero-shot beállításban mindkét modell teljesítménye drasztikusan romlik, különösen open-world esetben, ami a domain shift egyik legfontosabb gyakorlati kihívását mutatja. A Triplet MLP ugyanakkor stabilabb zero-shot értékeket ad (Standard Zero-Shot: DL 23.01% vs. RF 15.08%), ami a beágyazások általánosíthatóságára utal. Az *optimized* track-ek több forgatókönyvben javítást hoznak, de a javulás nem egyenletes, ezért a *shared* beállítás jó kompromisszumot ad a konszisztencia és teljesítmény között.

## 9 Korlátok

- A vizsgálat aggregált folyamjellemzőkre épül, ami részben elfedheti a finom időbeli mintázatokat.
- Az open-world „Other” osztály sokféle weboldal forgalmát fogja össze, ezért a modell nehezebben választja el a zárt világú osztályoktól, ami csökkentheti a precíziós mutatókat.

## 10 Következtetések és jövőbeli munka

A projekt igazolja, hogy a klasszikus és mélytanulási modellek eltérő erősségekkel rendelkeznek a Tor WF feladatban. A Random Forest magas baseline teljesítményt ad, míg a Triplet MLP zero-shot helyzetekben jobb általánosítást mutat. A jövőben a drift-roboosztus tanítás, adaptív újratanulás, és finomabb idősoros jellemzők integrálása lehet indokolt. Emellett érdemes a hosszabb időhorizonton gyűjtött adatok elemzése és a modellfrissítés költség-hatékonyságának vizsgálata.

### Hivatkozások

- [1] Cherubin, G., et al. (2022). *A study on concept drift in website fingerprinting*.
- [2] Sirinam, P., et al. (2019). *Deep Fingerprinting: Undermining Website Fingerprinting Defenses with Deep Learning*.