



Önálló laboratórium beszámoló

Távközlési és Mesterséges Intelligencia Tanszék

Készítette:	Pálos Ferenc
Neptun-kód:	U1OTPN
Szakirány:	Mérnökinformatika, Intelligens hálózatok
E-mail cím:	palosferenc@proton.me
Konzulens:	Dr. Ladóczki Bence
E-mail cím:	ladoczki.bence@vik.bme.hu

Téma címe: Weboldal-ujjlenyomat-készítés (website fingerprinting) vizsgálata Tor hálózaton

Feladat:

A Tor egy népszerű anonimizáló hálózat, amely napi több millió felhasználó adatvédelmét szolgálja önkéntesek által üzemeltetett proxyk (köztes átjátszó szerverek) segítségével. Célja, hogy elrejtse a kommunikáció forrását és célját, védve a felhasználókat a megfigyeléstől és a cenzúrától. Az anonimitást fenyegető egyik legjelentősebb támadási forma a weboldal-ujjlenyomat-készítés (website fingerprinting, WF), amely során a támadó a Tor hálózatba való belépési pont forgalmából következtethet a meglátogatott oldalakra. A projekt célja annak vizsgálata, hogy a WF támadások mekkora valós fenyegetést jelentenek a Tor felhasználóira, és hogy különböző forgalmi környezetekben – normál Tor forgalomban (baseline) és obfs4 pluggable transport (forgalom-elfedő modul) mellett –, illetve ismeretlen webhelyekkel bővített (nyílt világú) beállításban hogyan változik a gépi tanulási modellek teljesítménye.

Ennek részeként elvárás a valós forgalmi minták gyűjtése szimulált környezetben, etikus keretek között, az adatok előkészítése a gépi tanuláshoz, valamint egy egységes jellemzőter és a top-10 leginformatívabb jellemző kiválasztási stratégiájának kialakítása az alkalmazott modelles családok teljesítményének összehasonlíthatósága érdekében.

A munka második részeként két eltérő megközelítés kidolgozása és kiértékelése szükséges: egy klasszikus gépi tanulási megoldás (Random Forest) és egy reprezentáció-tanuláson alapuló architektúra (Triplet MLP + KNN), amely egy tanult beágyazási téren alkalmaz KNN osztályozást. A kiértékelésnek egységes metrikákkal (pontosság, macro-F1) és az eredmények grafikus ábrázolásával kell történnie. A tanítási és tesztelési adatok eloszlás-eltolódását (domain shift), amely a baseline és az obfs4 adatok közti különbségből adódik, valamint a zero-shot beállítások hatását – ahol a betanítás és a tesztelés eltérő környezetben történik – szintén számszerűsíteni kell.

Tanév: 2025/26. tanév, II. félév

1. A laboratóriumi munka környezetének ismertetése, a munka előzményei és kiindulási állapota

1.1. Bevezető

Jelen beszámoló a Tor hálózaton végzett weboldal-ujjlenyomat-készítés (website fingerprinting, WF) támadás vizsgálatát tárgyalja. A Tor célja a felhasználók anonimitásának megőrzése, ugyanakkor a Tor hálózatba való belépési ponton látható forgalmi mintázatok alapján egy külső megfigyelő következtethet a meglátogatott weboldalakra. Ezen támadási módszert azért fontos a gyakorlatban vizsgálni, mert a weboldalak felépítése és a hálózati környezet állapota (pl. csomópontok terhelése, obfs4 használata) időben változik, ami befolyásolja a támadás teljesítményét. A módszer stabilitásának felméréséhez ezt a változást számszerűsíteni kell. A Tor ökoszisztémában emellett megjelentek a forgalom-elfedést célzó technikák (pl. obfs4 pluggable transport) is, ezért a jelen vizsgálat zárt világú (closed-world), nyílt világú (open-world), valamint zero-shot beállításokat egyaránt tartalmaz. Zárt világ esetén a modell csak az előre ismert weboldalakat különbözteti meg, nyílt világban viszont az ismeretlen oldalak egy közös, „Other” gyűjtőosztályba kerülnek. A zero-shot kiértékelés során a modell betanítása egy adott környezetben történik, majd az értékelést egy attól eltérő környezetből származó forgalmon (pl. normál Tor forgalmon tanítva, de obfs4 forgalmon tesztelve) hajtja végre.

Korábbi kutatások [2] rámutattak, hogy a WF támadások a Tor hálózat valós forgalmában is releváns fenyegetést jelentenek, ami indokolja a gyakorlati körülmények közötti vizsgálatukat. A beszámoló fókuszban ennek megfelelően az eloszlás-eltolódás (domain shift) mérése – azaz a baseline és az obfs4 forgalom statisztikai eltéréseinek vizsgálata –, a zero-shot általánosítási képesség elemzése, valamint a nyílt világú, ismeretlen forgalom kezelése.

A munka gyakorlati célja egy teljes mértékben reprodukálható adatfeldolgozási lánc (pipeline) felépítése volt: a nyers PCAP (packet capture) állományokból kiindulva, a jellemzők kinyerésén és a modellek betanításán át, egészen a kiértékelési metrikák kiszámításáig és az eredmények vizualizációjáig. A vizsgálat keretében két eltérő modellcsalád kerül összehasonlításra: egy klasszikus gépi tanulási megoldás (Random Forest) és egy reprezentáció-tanuláson alapuló architektúra (Triplet MLP + KNN).

1.2. Elméleti összefoglaló

A WF során a támadó nem a hálózati forgalom tartalmát, hanem annak metaadatait (csomagméret, irány, érkezési idők) figyeli meg, és ezekből próbálja azonosítani a meglátogatott weboldalt. A probléma tipikusan egy felügyelt osztályozási feladat, ahol minden weboldal egy önálló osztályt képvisel, a mintákat pedig a weboldal-látogatások forgalmi lenyomatai alkotják. Zárt világú (closed-world) beállításban kizárólag előre ismert osztályok léteznek, nyílt világban (open-world) viszont megjelenik egy aggregált „Other” kategória is, amely az ismeretlen webhelyeket foglalja magában. A zero-shot beállítás esetén a modell kiértékelése olyan forgalmon történik, amely eltérő környezetből származik (pl. baseline adaton történő betanítás után obfs4 forgalmon), így a tesztadatok jellemzői eltérnek a tanító adatokétól.

A tanítási és tesztelési adatok eloszlásának eltérése (eloszlás-eltolódás, domain shift) azt jelenti, hogy ugyanazon webhelyek forgalmi statisztikái megváltoznak a baseline és az obfs4 környezet között (pl. a csomagok időköz- és méretstatisztikái eltolódnak). Mivel ez a jelenség az adott környezetben betanított modellek teljesítményének jelentős degradációjához vezethet új környezetben, a kiértékelési keretrendszerben kiemelt szerepet kap a baseline és az obfs4 forgalom összevetése, valamint a zero-shot teljesítmény mérése.

A WF támadások vizsgálata alapvetően két fő irányra bontható. Az egyik a kézzel tervezett (hand-crafted), aggregált jellemzők használata, ahol egy-egy kapcsolatot leíró statisztikák (pl. csomagszámok, bájtstatisztikák, időtartam, irányváltások) kerülnek a modell bemenetére. A másik a mélytanulási megközelítés, amely a reprezentációt közvetlenül az adatokból tanulja meg [3]. Jelen munka mindkét irányt alkalmazza: a Random Forest egy robusztus, jól értelmezhető klasszikus algoritmusként szolgál, míg a Triplet MLP egy tanult beágyazási térben végzi a KNN-alapú osztályozást.

A modellek teljesítményének elsődleges mérőszámai a pontosság (accuracy) és a macro-F1 érték, mivel többosztályos problémák esetén ezek biztosítják a teljesítmény kiegyensúlyozott megítélését. Nyílt világú beállításnál kiemelt fontosságú az „Other” osztály visszahívása (recall) is, hiszen ez mutatja meg, hogy a modell milyen hatékonysággal képes az ismeretlen forgalmat elkülöníteni a már ismert, zárt világú osztályoktól.

1.3. Laboratóriumi környezet és eszközök

A mérések és a kiértékelési pipeline egyetlen, kontrollált laboratóriumi környezetben futott, hogy a Tor és a pluggable transport viselkedését ne befolyásolja külső zaj. Az alábbi paraméterek szükségesek ahhoz, hogy a környezet mások számára is reprodukálható legyen:

- **Operációs rendszer és kernel:** Linux Mint 22.2 (Zara), kernel 6.14.0-37-generic.
- **Hardver:** Intel Core i5-5200U (2 mag / 4 szál), 7.7 GiB RAM, lemez: 1 TB WDC WD10JPVX + 1 TB WDC WD1003FZEX, interfész: enp3s0.
- **Tor/obfs4 verziók:** Tor 0.4.8.10, obfs4proxy 0.0.14.
- **Böngésző és automatizálás:** Chromium 145.0.7632.116 + ChromeDriver 145.0.7632.116, Selenium alapú headless vezérlés.
- **Capture eszköz:** tcpdump 4.99.4 (libpcap 1.10.4).
- **Tor konfiguráció:** TOR_WF_INTERFACE=enp3s0, TOR_WF_GUARD_IP=109.110.170.208, TOR_WF_CAPTURE_DTOR_WF_WARMUP_DURATION=3s, SOCKS (helyi proxy) 127.0.0.1:9050, ControlPort (vezérlő port) 127.0.0.1:9051.

1.4. A munka állapota, készültségi foka a félév elején

A laboratóriumi munka megkezdésekor nem állt rendelkezésre korábbi forráskód, rögzített adathalmaz vagy előzetes mérési eredmény. A projekt kiindulási alapját kizárólag a feladatkiírás, az egyeztetett munkaterv, valamint az előzetes egyetemi tanulmányok során elsajátított elméleti ismeretek (gépi tanulás, hálózati forgalom menedzsment) képezték. Ennek megfelelően a megvalósítás az alapoktól indult: az első fázis a mérési infrastruktúra, az adatfeldolgozási lánc (pipeline), valamint a kiértékelési keretrendszer teljes körű kialakítását foglalta magában.

2. Az elvégzett munka és az eredmények ismertetése

2.1. Áttekintés

Jelen beszámoló a Tor hálózaton végzett weboldal-ujjlenyomat-készítés (WF) támadás átfogó vizsgálatát mutatja be, két eltérő modellcsalád összehasonlításával: egy klasszikus gépi tanulási algoritmus (Random Forest, RF) és egy mélytanulás-alapú architektúra (Triplet MLP + KNN, DL) bevonásával. A modellek teljesítményének mérése zárt világú (closed-world) és nyílt világú (open-world) osztályozási feladatokon, valamint domáinek közötti (zero-shot) forgatókönyvek alapján történik, mind normál Tor (baseline), mind forgalom-elfedő (obfs4) környezetben.

Az eredmények alapján a Random Forest algoritmus magasabb osztályozási pontosságot ér el a meg-egyező környezetben tanított és tesztelt (baseline és obfs4) esetekben, míg a Triplet MLP robusztusabbnak bizonyul, és jobban általánosít a zero-shot kiértékelés során. A dokumentum részletesen tárgyalja a szimulált adatgyűjtés folyamatát és az automatizált adatfeldolgozási lánc lépéseit is, ezáltal biztosítva az eredmények teljes reprodukálhatóságát.

2.2. Célkitűzések és hozzájárulások

A projekt elsődleges célja egy reprodukálható WF adatfeldolgozási lánc (pipeline) kialakítása, valamint két eltérő modellcsalád objektív összehasonlítása volt. A kiértékelés kiemelt hangsúlyt fektet a Tor forgalomban jelentkező eloszlás-eltolódásra (domain shift), azaz a tanítási és tesztelési adatok statisztikai eltérésére, illetve az ismeretlen forgalom (nyílt világú beállítás) kezelésére. A jellemzőkiválasztás (feature selection) során két stratégia került meghatározásra: a *shared* beállítás esetén a top-10 jellemző kiválasztása minden futás (seed) alkalmával egy összevont (pooled) tanítóhalmazon történik, míg az *optimized* megközelítés forgatókönyvenként (pl. baseline, obfs4) külön határozza meg a leginformatívabb top-10 jellemzőt több futás fontossági átlaga alapján.

A munka legfőbb hozzájárulásai a következők:

- Egy teljesen automatizált feldolgozási lánc implementálása, amely a nyers PCAP állományok feldolgozásától a kiértékelési metrikák kiszámításáig terjed.
- Aggregált folyamjellemzők (flow features) definiálása és egy egységes, 21 dimenziós jellemzőtér kialakítása.
- Két eltérő top-10 jellemzőkiválasztási stratégia (*shared, optimized*) implementálása és összehasonlítása.
- Egységes és automatizált vizualizációs modul (ábragenerálás) létrehozása a kiértékelés során keletkező JSON eredményfájlok alapján.
- A nyílt világú „Other” osztály kezelésének, valamint a zero-shot általánosítási képességnek az elkülönített, önálló mérési forgatókönyvként történő kiértékelése.

2.3. Adatok és beállítások

A kiértékelés három fő forgalmi tartományon (domain) történik: normál Tor forgalom (baseline), forgalom-elfedő modullal (pluggable transport) generált forgalom (obfs4), valamint a nyílt világú ismeretlen forgalom („Other” kategória). Az egyes vizsgálati forgatókönyvek (szcenáriók) az adatkörnyezet és a kiértékelési mód kombinációjából épülnek fel. A fő beállítások az alábbiak:

- **Baseline (zárt világú):** Normál Tor forgalom, kizárólag előre ismert osztályokkal (weboldakkal).
- **Obfs4 (zárt világú):** Obfs4 protokoll által elfedett forgalom, kizárólag előre ismert osztályokkal.
- **Zero-shot:** Baseline forgalmon betanított modellek tesztelése obfs4 forgalmon (a domáinek közötti általánosítási képesség vizsgálata).
- **Nyílt világú (Open-world):** Az „Other” kategória bevonása az ismeretlen weboldalak modellezésére.


Az elemzéshez rögzített adatkészlet főbb paraméterei:

- **Monitorozott oldalak száma:** 36 zárt világú (ismert) célpont.
- **Mintaszám célpontonként:** Baseline környezetben 30–34 minta/webhely (összesen 1123 PCAP); obfs4 környezetben 29–30 minta/webhely (összesen 1050 PCAP); az „Other” kategóriában 2–5 minta/webhely (összesen 64 PCAP).
- **„Other” kategória összetétele:** 20 különböző, a zárt világú halmazban nem szereplő (ismeretlen) webhely.
- **Adatgyűjtési paraméterek:** három másodperc bemelegítési (warmup) fázis, amelyet 15 másodperc aktív rögzítés (capture) követett.

A zárt világú osztályok esetén a kiértékelés rétegzett (stratified) 80%/20% arányú tanító/teszt felosztással történik. A nyílt világú „Other” osztály esetében ezzel szemben 50%/50%-os arányú a szétválasztás, mivel itt nem a konkrét webhelyek osztályozása a cél, hanem az ismeretlen forgalom megbízható felismerése (általánosítás). A megnövelt arányú tesztalmaz valósághűbb ismeretlen mintaállományt biztosít, csökkenti a visszahívás (recall) becslésének statisztikai zaját, és alacsonyabb összmintaszám esetén is robusztusabb kiértékelést tesz lehetővé.

2.4. Adatgyűjtés és előfeldolgozás

Az adatgyűjtés automatizált, grafikus felület nélküli (headless) böngésző és a `tcpdump` csomagrögzítő eszköz segítségével történik, aktív Tor SOCKS proxy és ControlPort kapcsolat alkalmazása mellett. A SOCKS proxy a böngésző teljes forgalmát a Tor hálózatba irányítja, míg a ControlPort a helyi Tor példány vezérlését (pl. új hálózati áramkörök – *circuit* – felépítésének kikényszerítése, állapotlekérdezés) biztosítja. A baseline, az obfs4 és az „Other” adathalmazok egymástól elkülönített mérési fázisokból származnak.



1. ábra. A feldolgozási lánc fő lépései a nyers PCAP fájloktól az eredmények vizualizációjáig.

1. táblázat. Az aggregált folyamjellemzők főbb csoportjai és példái.

Csoport	Jellemzők (példák)
Csomagszámok	pl. total_packets, in_out_packet_ratio
Bájtstatisztikák	pl. total_bytes, incoming_bytes
Időköz-statisztikák	pl. mean_inter_arrival, p90_inter_arrival
Méretstatisztikák (összes)	pl. max_packet_size, mean_packet_size
Méretstatisztikák (irány)	pl. incoming_mean_packet_size, outgoing_std_packet_size
Időtartam és dinamika	pl. duration, direction_changes

Az adatgyűjtő keretrendszer rugalmasan paraméterezhető (pl. célkönyvtár, vizsgált hálózati interfész, rögzítési és bemelegítési időablakok megadása). A bemelegítési (warmup) fázis alkalmazása azért kritikus fontosságú, mert ez biztosítja a Tor hálózati útvonalak stabilizálódását még a tényleges csomagrögzítés (capture) megkezdése előtt. A rendszer reprodukálásához szükséges részletes konfigurációs és futtatási utasításokat a mellékelt README dokumentáció tartalmazza.

2.5. Feldolgozási pipeline és jellemzők

Az adatfeldolgozási lánc három fő lépésből áll. **(1)** A nyers PCAP fájlok feldolgozása során megtörténik a hálózati csomagok kinyerése, majd ezekből csomagonkénti idősorok (érkezési idő, csomagméret, forgalom iránya) generálása. **(2)** Ezen idősorok alapján egy-egy hálózati kapcsolatot leíró, aggregált folyamjellemzők (flow features) kiszámítására kerül sor. Ilyenek például a be- és kimenő csomagok és bájtok összesített száma, a csomagok közötti érkezési idők (inter-arrival times) statisztikai mutatói (átlag, szórás, kvantilisek), a kapcsolat teljes időtartama, valamint az irányváltások száma. **(3)** A gépi tanulási modellek betanítása és kiértékelése ezen a kinyert jellemzőtérén történik. A 21 dimenziós alap jellemzőtérből a kiértékelés során minden futás alkalmával a leginformatívabb top-10 jellemző kerül kiválasztásra, így biztosítva a modellek teljesítményének egységes dimenziószámon történő összehasonlítását. A kinyert jellemzők főbb csoportjait és reprezentatív példáit az 1. táblázat szemlélteti.

2.6. Modellek és kiértékelés

Random Forest (RF). A klasszikus gépi tanulási modell 300 döntési fát alkalmaz. A stabilizált top-10 jellemzőkiválasztás mellett, a robusztus kiértékelés érdekében a betanítás és tesztelés három különböző véletlen adatfelosztással (random seed) történik. A modell teljesítményének statisztikai megbízhatóságát a három független futás eredményeiből számított átlag és szórás biztosítja.

Triplet MLP + KNN (DL). A mélytanulási architektúra egy többrétegű perceptronból (MLP) áll, amely egy 32 dimenziós beágyazási teret (embedding space) tanul. A hálózat optimalizálása Triplet Margin Loss hibafüggvénnyel történik, amely arra kényszeríti a modellt, hogy az azonos osztályba (weboldalhoz) tartozó minták távolsága a beágyazási térben minimális, míg a különböző osztályoké maximális legyen. A végső osztályozás az így kinyert beágyazásokon egy $k = 5$ paraméterű k -legközelebbi szomszéd (KNN) algoritmussal történik.

Jellemzőkiválasztási módok. A kiértékelés során kétféle stratégia kerül alkalmazásra. A *shared* beállítás esetén minden vizsgálati forgatókönyv az adott futáshoz (seed) tartozó, összevont adathalmazon számított kölcsönös információ (mutual information) alapján meghatározott top-10 listát használja. Az *optimized* beállítás ezzel szemben forgatókönyvenként (pl. baseline, obfs4) dedikált top-10 jellemzőkészletet állít elő; ehhez az RF több futásból stabilizált fontossági rangsort, a DL modell pedig mutual information metrikát alkalmaz.

2.7. Kiértékelési metrikák

A modellek teljesítményének mérése elsősorban az osztályozási pontosság (accuracy) és a macro-F1 metrikák alapján történik. A pontosság a helyesen besorolt minták arányát mutatja a teljes adathalmazon, míg a macro-F1 az egyes osztályokon külön-külön kiszámított F1-pontszámok számtani átlaga:


$$\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\hat{y}_i = y_i], \quad \text{MacroF1} = \frac{1}{C} \sum_{c=1}^C \text{F1}_c, \quad (1)$$

ahol N az összes minta száma, C az osztályok száma, y_i és $\hat{y}_i$ pedig a valós, illetve a modell által prediktált címke.


Nyílt világú (open-world) beállítás esetén külön kiértékelésre kerül az „Other” kategória visszahívási (recall) értéke is. Ennek vizsgálata azért kritikus, mert ez a metrika számszerűsíti, hogy az alkalmazott modell milyen hatékonysággal képes az ismeretlen forgalmat leválasztani az előre ismert, zárt világú osztályokról.

2.8. Ábrák és vizuális összegzés


Az ábrák a mentett metrikákból automatikusan készülnek, ezért az ábrák és a táblázatok ugyanabból a kiértékelési kimenetből készülnek. Az ábrák célja, hogy a fő trendeket gyorsan összegezze, majd részletesebb bontást adjon beállítás, jellemzőkiválasztási mód és osztályszintű viselkedés szerint. A zárt világú összegzést a 2. ábra mutatja, míg a beállításonkénti macro-F1 és pontosság változását a 3. és 4. ábrák összesítik. A *shared* és *optimized* beállítások különbségeit a 5. ábra emeli ki, a nyílt világú beállítások közti eltéréseket pedig a 6. ábra foglalja össze. A jellemzőkiválasztás hatását és stabilitását a 7., 8. és 9. ábrák szemléltetik. Az osztályszintű viselkedést a 10. konfúziós mátrixai, az ismeretlen forgalom elkülönítését pedig a 11. ábra jelzi.




2. ábra. Zárt világú teljesítmény-összegzés (pontosság és macro-F1) a két modellre.




3. ábra. Macro-F1 alakulása minden beállításban, zárt és nyílt világú esetekben.




4. ábra. Pontosság alakulása minden beállításban, zárt és nyílt világú esetekben.




5. ábra. A *shared* és *optimized* beállítások közti különbségek (delta) pontosságban és macro-F1-ben.





6. ábra. Nyílt világú beállítások összehasonlítása.



7. ábra. A top-10 jellemzők fontossága a közös (shared) kiválasztás mellett.




8. ábra. Beállításonként optimalizált top-10 jellemzők összehasonlítása.

9. ábra. A top-10 jellemzők stabilitása Random Forest esetén (átlag $\pm$ szórás a több futásból).

(a) Alap konfúziós mátrixok.

(b) Recall-normalizált változatok.

10. ábra. Konfúziós mátrixok a főbb beállításokban (shared beállítás, seed=42).



11. ábra. Az „Other” osztály recall értékei a nyílt világú beállításokban.

2.9. Kísérleti beállítások

A tanítás és kiértékelés minden esetben rétegzett (stratified) tanító/teszt adatfelosztással történik. A zárt világú osztályoknál ez a felosztás 80%/20% arányú, míg a nyílt világú „Other” osztály esetén 50%/50%-os arány kerül alkalmazásra, ami az ismeretlen forgalomra való általánosítás robusztusabb mérését szolgálja. Az eredmények statisztikai stabilitását három független, véletlenszerű adatfelosztás (random seed) alkalmazása biztosítja. A modellek teljesítményének mérése pontosság (accuracy) és macro-F1 metrikákkal történik, a jelentett értékek pedig az ismételt futások átlagát és szórását mutatják (átlag $\pm$ szórás). A zero-shot kiértékelés során a betanítás a baseline adatokon, míg a tesztelés a normál Tor forgalomtól eltérő, obfs4 adatokon történik. Ezen forgatókönyvek *shared* jellemzőkiválasztási beállítással elért eredményeit a 2. és 3. táblázatok foglalják össze.

2.10. Reprodukálhatóság és futtatás

Mivel az adatfeldolgozási lánc elméleti lépéseit a korábbi szakaszok már tárgyalták, ez a rész a szoftveres reprodukálhatóságot biztosító elemekre szorítkozik. A teljes futtatási környezet, a Python függőségek (dependencies), valamint a projekt könyvtárszerkezetének részletes leírása a mellékelt README dokumentációban található. A leadott laboratóriumi anyagok magukban foglalják a teljes forráskódot, a rögzített PCAP állományokat, a kinyert jellemzőket tartalmazó fájlokat, valamint a kiértékelési metrikákat és a vizualizációkat. Ennek köszönhetően a bemutatott mérések és ábragenerálási folyamatok külső beavatkozások nélkül, teljes egészében újrafuttathatók.

2.11. Eredmények

A zárt világú kiértékelések eredményeit a 2. táblázat, a nyílt világú beállítások (Open-World) mérőszámait pedig a 3. táblázat összesíti. A dokumentumban később bemutatásra kerülő vizualizációk (2., 3. és 4. ábrák) numerikus alapját teljes egészében ezek a mérések adják.

2.12. Elemzés és megvitatás

A kapott eredmények alapján a Random Forest algoritmus a zárt világú baseline és obfs4 beállításokban egyértelműen magasabb pontosságot és macro-F1 értéket ér el, ami a kézzel tervezett (hand-crafted) aggregált jellemzők hatékony reprezentációs képességét igazolja (lásd a 2. és 4. ábrát, valamint a 2. táblázatot). A zero-shot forgatókönyv esetén mindkét modell teljesítménye drasztikus degradációt szenved el a normál környezethez képest, ami a baseline és az obfs4 forgalom közötti eloszlás-eltolódás (domain shift) erőteljes gyakorlati hatására mutat rá (lásd a 3. és 6. ábrát). Érdekeség ugyanakkor, hogy a nyílt világú zero-shot pontosság magasabb (RF: 22,73%, DL: 27,27%), mint a zárt világú (RF: 15,08%, DL: 23,01%). Ez a látszólagos javulás nem a modellek robusztusságából fakad, hanem a nyílt világú tesztkörnyezet sajátosságának a következménye: a modellek az ismeretlen („Other”) osztályra rendkívül magas visszahívási (recall) értéket érnek el (lásd a 11. ábrát), ami az osztály mintaeloszlása miatt mesterségesen megemeli az összesített pontosságot, miközben a macro-F1 értékek elhanyagolható szinten maradnak (RF: 10,41%, DL: 18,42%). A Triplet MLP ugyanakkor számottevően stabilabb zero-shot teljesítményt nyújt (Zárt világú Zero-Shot: DL 23,01% vs. RF 15,08%), ami a tanult beágyazási tér robusztusabb általánosítási képességére utal.

Bár az *optimized* jellemzőkiválasztási beállítás több esetben kismértékű javulást eredményez, ez az előny nem konzisztens. Emiatt a *shared* beállítás optimális kompromisszumot biztosít a modellek összehasonlíthatósága és a prediktív teljesítmény között (lásd az 5. ábrát). A top-10 lista stabilitása azt bizonyítja, hogy a leginformatívabb aggregált jellemzők robusztusak a tanító- és tesztalmaz véletlenszerű felosztásával szemben (lásd a 9. ábrát). A nyílt világú beállításokban a visszahívásra (recall) normalizált konfúziós

2. táblázat. Zárt világú (Standard) beállítások eredményei.

Beállítás	RF Acc.	RF Macro-F1	DL Acc.	DL Macro-F1
Baseline	80.44 $\pm$ 0.96	79.76 $\pm$ 0.99	61.19 $\pm$ 2.22	60.23 $\pm$ 2.47
Obfs4	73.33 $\pm$ 1.78	71.88 $\pm$ 1.57	50.64 $\pm$ 2.59	49.48 $\pm$ 2.70
Zero-Shot	15.08 $\pm$ 1.37	10.83 $\pm$ 1.57	23.01 $\pm$ 2.59	18.54 $\pm$ 2.64

3. táblázat. Nyílt világú (Open-World) beállítások eredményei.

Beállítás	RF Acc.	RF Macro-F1	DL Acc.	DL Macro-F1
OW-Baseline	80.93±0.84	79.11±0.68	62.00±1.32	60.37±0.76
OW-Obfs4	74.10±1.59	71.03±1.65	48.90±2.58	48.46±1.78
OW-Zero-Shot	22.73±1.79	10.41±1.00	27.27±1.79	18.42±0.41

mátrixok jól szemléltetik, hogy a modellek az „Other” kategóriát többnyire sikeresen különítik el a zárt világú osztályoktól, ugyanakkor ez a magas felismerési arány gyakran a precízió (precision) rovására történik (lásd a 10b. és 11. ábrát).

2.13. Korlátok

A mérési módszertan és a kiértékelés az alábbi korlátokkal rendelkezik:

- A vizsgálat kizárólag aggregált folyamjellemzőkre épül, ami az eredeti csomag-idősorok finom dinamikai mintázatainak elvesztésével járhat.
- Mivel a nyílt világú „Other” osztály rendkívül heterogén (ismeretlen weboldalak sokaságának forgalmát aggregálja), a modellek számára komoly kihívást jelent ennek éles határvonalú elkülönítése a prediktálható, zárt világú osztályoktól, ami törvényszerűen a precíziós mutatók csökkenését eredményezi.
- A radikális dimenziócsökkentés (kizárólag a top-10 jellemző statikus megtartása) következtében a ritkábban előforduló, ám egy-egy osztály esetében lokálisan informatív mintázatok prediktív ereje elveszhet.

2.14. Következtetések és jövőbeli munka

A projekt igazolja, hogy a klasszikus és a mélytanulás-alapú modellek eltérő erősségekkel rendelkeznek a Tor hálózaton végzett WF támadások vizsgálatában. Míg a Random Forest algoritmus a baseline környezetben magasabb osztályozási pontosságot ér el, addig a Triplet MLP architektúra a zero-shot forgatókönyvek során bizonyul robusztusabbnak, és jobban általánosít az ismeretlen környezetekre. Mivel a hálózati forgalom statisztikai eloszlása időben változik (concept drift), a jövőbeli kutatások során érdemes több időszakból és mindkét adatkörnyezetből (baseline, obfs4) kiterjedtebb tanítóadat-halmazt gyűjteni, majd a modelleket egy időben elkülönített (time-separated) tesztalacson kiértékelni. Ezt a megközelítést kiegészítheti a modellek friss mintákon történő periodikus újratanítása, valamint a komplexebb idősoros jellemzők (nyers csomag-idősorok, burst-mintázatok, n-gram vagy reprezentáció-tanuláson alapuló leírások) bevonása. Végül indokolt a modellfrissítés költséghatékonyságának számszerűsítése is: vizsgálni kell, hogy mennyi új adat és számítási kapacitás szükséges egy adott teljesítménynövekedés eléréséhez, illetve milyen frissítési gyakoriság biztosítja az optimális kompromisszumot.

2.15. Összefoglalás

A laboratóriumi munka során egy teljes mértékben reprodukálható WF adatfeldolgozási lánc (pipeline) került kialakításra, amely a nyers PCAP állományok kinyerésétől a kiértékelési metrikák kiszámításáig és az eredmények vizualizációjáig biztosít egy egységes, automatizált keretrendszert. A végrehajtott kísérletek rámutattak, hogy a Random Forest algoritmus a baseline és az obfs4 környezetekben magasabb osztályozási pontosságot ér el, míg a Triplet MLP architektúra a zero-shot beállítások esetén robusztusabb általánosítási képességgel rendelkezik. A nyílt világú vizsgálatok igazolták, hogy az ismeretlen forgalmat aggregáló „Other” osztály leválasztása lehetséges, azonban ennek precíziója jelenleg korlátozott. A mérések legfőbb tanulsága, hogy a baseline és az obfs4 forgalom statisztikai eloszlása szignifikánsan eltér (domain shift). Ennek feloldása érdekében a jövőbeli kutatások fókuszába a heterogén környezetekből származó adatokon betanított modellek, valamint a mélyebb, idősoros forgalmi mintázatok vizsgálata kell, hogy kerüljön.

3. Irodalom és csatlakozó dokumentumok jegyzéke

3.1. A tanulmányozott irodalom jegyzéke

3.2. A tanulmányozott irodalom jegyzéke

- [1] R. Dingledine, N. Mathewson, and P. Syverson, „Tor: The Second-Generation Onion Router,” in *Proc. 13th USENIX Security Symposium (USENIX Security '04)*, San Diego, CA, USA, 2004, pp. 303–320. [Online]. Elérhető: <https://www.usenix.org/conference/13th-usenix-security-symposium/tor-second-generation-onion-router> (Letöltve: 2026. május 20.)
- [2] G. Cherubin, R. Jansen, and C. Troncoso, „Online Website Fingerprinting: Evaluating Website Fingerprinting Attacks on Tor in the Real World,” in *Proc. 31st USENIX Security Symposium (USENIX Security '22)*, 2022, pp. 753–770. [Online]. Elérhető: <https://www.usenix.org/conference/usenixsecurity22/presentation/cherubin> (Letöltve: 2026. május 20.)
- [3] P. Sirinam, M. Imani, M. Juarez, and M. Wright, „Deep Fingerprinting: Undermining Website Fingerprinting Defenses with Deep Learning,” in *Proc. 2018 ACM SIGSAC Conf. Computer and Communications Security (CCS '18)*, Toronto, ON, Canada, 2018, pp. 1928–1943. DOI: <https://doi.org/10.1145/3243734.3243768> (Letöltve: 2026. május 20.)
- [4] Y. Angel (The Tor Project), „obfs4: The obfourscator,” Tor Project, 2014. [Online]. Elérhető: <https://gitlab.com/yawning/obfs4> (Letöltve: 2026. május 20.)
- [5] L. Breiman, „Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. DOI: <https://doi.org/10.1023/A:1010933404324>
- [6] E. Hoffer and N. Ailon, „Deep Metric Learning Using Triplet Network,” in *Similarity-Based Pattern Recognition*, 2015, pp. 84–92. DOI: https://doi.org/10.1007/978-3-319-24261-3_7.

3.3. A csatlakozó dokumentumok jegyzéke

A projekt reprodukálásához szükséges teljes forráskód, az adatgyűjtési környezet és a dokumentáció elérhető a publikus GitHub repozitóriumban:

Pálos Ferenc: Tor Website Fingerprinting Pipeline

Elérhető: <https://github.com/palosferi/onlab>

A beadott csatlakozó anyagok a projekt lokális könyvtárában az alábbi struktúra szerint találhatóak:

- `src/` – A feldolgozási és kiértékelési pipeline implementációja.
- `scripts/collection/` – Az automatizált adatgyűjtést végző szkriptek.
- `figures/` – A kiértékelés során keletkezett nyers JSON metrikák és a generált ábrák.
- `tor_dataset/` – A mérések alapjául szolgáló nyers PCAP állományok.
- `irasbeli_beszamolo/figs/` – A beszámoló fordításához szükséges lokális ábrák.